

# 시점 종속 색상을 위한 텍스처 복원\*

김승진<sup>0</sup>, 이승용  
포항공과대학교  
{kimsj0302, leesy}@postech.ac.kr

## Texture Reconstruction for View-dependent Colors

Soongjin Kim<sup>0</sup>, Seungyong Lee  
POSTECH

### 요약

최근 딥 러닝 기반의 뉴럴 렌더링은 딥러닝의 높은 표현력을 기반으로 고품질의 이미지를 생성할 수 있다. 하지만 대부분의 딥 러닝 기반의 렌더링 방식은 시간이 오래 걸리며 장면을 변형하기 어렵다. 본 연구에서는 이러한 문제를 해결하기 위하여 새로운 뉴럴 텍스처 모델을 제안한다. 제안하는 방식은 시점에 따른 색을 표현하면서 장면 편집이 용이하며 빠른 속도로 동작할 수 있다. 이러한 방식은 시점에 따른 색을 복원하는데 장점을 가지며 일부 지점에서는 기존 연구를 뛰어넘는 시각적 결과를 보인다.

### 1. 서론

Neural Radiance Field (NeRF)[1]는 주어진 영상들을 통해 새로운 시점에서의 고품질 영상을 합성할 수 있다. NeRF는 픽셀을 관통하는 가상의 3차원 선을 정의하고 이 선 위에서 3차원 지점을 추출하여 장면을 렌더링하는 볼륨 렌더링 기반의 방식을 사용한다. 이러한 방식은 각 추출된 지점들이 MLP에서 연산을 진행해야 하기 때문에 시간이 오래 걸린다는 단점이 있다. 또한 음함수 표현으로 3차원 공간을 나타내기 때문에 장면을 편집하기 어렵다.

최적화 기반의 텍스처 생성 방식[3]은 결과가 메시와 텍스처로 구성되기 때문에 NeRF와 같은 음함수 표현 방식과 달리 장면 편집이 용이하며 렌더링 속도가 빠르다는 장점이 있다. 하지만 각 영상의 카메라 위치와 메시의 품질에 영향을 크게 받아 때때로 고스팅 현상이 발생한다.

Stable view synthesis[2]는 메시를 기반으로 딥러닝 방식을 사용하여 장면을 합성하는 방법이다. 이 방법은 장면 합성에 필요한 시점 정보와 주어진 이미지들의 특성 벡터를 초기에 합성하기 때문에 텍스처의 형태로 표현이 어렵고 합성에도 시간이 오래 걸린다.

본 연구는 이와 같은 기존 영상 합성 방식의 문제를 해결하고자 새로운 뉴럴 텍스처 모델을 제안한다. 새로운 모델은 텍스처 표현 방식을 사용하기 때문에 기존에 사용되었던 다양한 메시 변형 알고리즘이 적용가능하다. 또한 딥러닝 방식에서 사용하는 특성 맵을 사용하기 때문에 고스팅 현상과 같은 최적화 기반 방법에서 발생하는 문제들이 적게 발생한다. 그리고 기존 텍스처에서는 시점에 따른 빛의 반사 등과 같은 시점에 종속적인 색상 변화에 처리하지 못한 반면 제안된 방법은 시점 정보를 네트워크의 추가적인 입력으로 사용하여 이러한 문제를 해결한다.

본 연구는 시점 종속 색상을 합성하는데 성공하였으며, 매우 빠른 속도로 색을 합성할 수 있다. 메시 복원 결과가 색상 합성 결과에 영향이 있으나 메시 복원 품질이 좋은 지점에 대해서는 기존 연구를 뛰어넘는 시각적인 결과를 보인다.




그림 1: 텍스처로부터 시점에 따른 색을 합성하는 파이프라인

### 2. 텍스처 생성 방식

이 장에서는 시점에 따른 색을 합성하는 텍스처 생성 방식을 서술 한다. 텍스처 생성을 위한 입력으로 카메라 위치를 알고있는 이미지들과 메시 복원 기술을 활용하여 얻은 3차원 메시가 주어진다. 본 연구에서는 COLMAP[4]과 Screened Poisson Reconstruction[5] 방식을 통해 3차원 메시와 이미지들의 카메라 위치를

\* 구두 발표논문

\* 본 논문은 2022 년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원(SW 스타랩, 2015-0-00174; 인공지능혁신허브사업, 2021-0-02068)과 2022 년도 정부(문화체육관광부)의 재원으로 한국콘텐츠진흥원의 지원(문화기술선도대학원, R2021040136)을 받아 수행된 연구입니다.

과악한다.

## 2.1. 렌더링 파이프라인

텍스처 맵에서 각 텍셀은  $N$ 차원 벡터이며 이는 시점에 따른 색상 정보를 저장한다. 주어진 메시 표면 위의 점에 대해서 대응되는 벡터를 텍스처 매핑을 통해 파악할 수 있다. 색 합성 함수  $M_r$ 은 시점 방향  $(\theta, \phi)$ 과 텍셀의 벡터를 통해 색을 합성한다(그림 1).

## 2.2. 특성 벡터 정합

하나의 텍셀이 가지는 벡터의 크기는 고정되어 있기 때문에 여러 이미지들의 정보를 정합하여 하나의 특성 벡터를 만들 필요가 있다. 이미지의 정보를 효과적으로 반영하기 위하여 미리 학습된 ResNet 네트워크를 사용하여 각 이미지에 대한 특성 맵을 생성한다. 각 이미지에 대한 카메라 위치와 이미지에 대한 특성 맵을 알고 있기 때문에 3차원 지점  $x$ 에 대해서 특성 벡터와 시점 방향에 대한 집합을 구성할 수 있다. 정합을 진행할 때에는 가중치를 계산하여 각 이미지에서의 특성 벡터를 가중합한다. 가중치는 해당 위치에서의 법선 벡터와 시점 방향의 내적을 통해 정의된다.




그림 2: 정성적 비교 결과. 빨간색과 파란색 사각형은 메시 복원 결과가 실제와 비슷한 부분, 검은색 사각형은 메시 복원 결과가 실제와 다른 부분에 대한 합성 결과를 보여준다.

## 2.3. 네트워크 학습

정합된 특성 벡터를 입력으로 두개의 MLP를 사용하여 학습을 진행한다. 첫번째 MLP는 정합된 특성 벡터를 같은 크기를 가지는 특성 벡터로 변형하고 두번째 MLP는 시점 방향 정보를 추가적으로 받아 색상 정보를 예측한다. 학습시에는 두개의 MLP를 모두 사용하여 학습을 진행한다. 학습이 완료되면 첫번째 MLP의 출력

결과를 바탕으로 텍스처를 구성하고 두번째 MLP만을 가지고 시점 종속 색상을 합성할 수 있다. 두번째 MLP는 간단한 구조로 구성되어 시점 종속 색상 예측 속도가 빠르다. 학습을 위한 손실 함수는 이미지 간의  $L2$  함수로 정의하였다.

## 3. 실험 결과

### 3.1. 정성적 비교

그림 2는 DTU 데이터셋에서의 이미지 합성 결과를 보여준다. 빨간 색 및 파란 색 사각형 영역에서는 NeRF[1]와 비교하였을 때 실제 이미지에 가까운 합성 결과를 보여준다. 하지만 검은 사각형 영역처럼 메시 복원 결과가 실제와 차이가 큰 부분에서는 실제 이미지와 가까운 합성 결과를 얻지 못하는 것을 확인할 수 있다.

표 1: 정량적 비교 결과

|         | LPIPS  | PSNR  | SSIM | 속도       |
|---------|--------|-------|------|----------|
| NeRF[1] | 0.2577 | 24.73 | 0.90 | 0.03 fps |
| Ours    | 0.3244 | 20.37 | 0.82 | 60 fps   |

### 3.2. 정량적 비교

표 1은 DTU 데이터셋에서의 정량적 비교 결과를 보여준다. 본 논문의 방식이 이미지 품질에 대한 성능 지표가 NeRF[1]보다 낮다. 이는 합성 결과가 메시 복원 성능에 영향을 받기 때문이다. 반면에, 본 연구는 간단한 구조만으로 이미지를 합성하기 때문에 합성 속도가 빠른 것을 확인할 수 있다. NeRF와 달리 제안한 텍스처 기반의 방식이 실시간 합성을 가능하도록 한다.

## 4. 결론

본 논문에서는 시점 종속 색상 정보를 복원하는 텍스처 생성 및 복원 방법에 대해서 제안하였다. 현재에는 기존 이미지 합성 방식들보다 이미지 품질은 낮지만 매우 빠른 속도를 보여준다. 현재 메시 복원 성능에 영향을 크게 받으나 추후 연구를 통해 메시 복원의 성능 저하에 강인한 색상 정보를 복원 기법을 연구할 것이다.

## 참고문헌

- [1] Mildenhall, Ben, et al. (2020). Nerf: Representing scenes as neural radiance fields for view synthesis. *ECCV*.
- [2] Riegler, G., & Koltun, V. (2021). Stable view synthesis. *CVPR*.
- [3] Fu, Y., Yan, Q., Liao, J., & Xiao, C. (2020). Joint texture and geometry optimization for RGB-D reconstruction. *CVPR*.
- [4] Schonberger, J. L., & Frahm, J. M. (2016). Structure-from-motion revisited. *CVPR*.
- [5] Kazhdan, M., & Hoppe, H. (2013). Screened poisson surface reconstruction. *ACM ToG*, 32(3), 1-13.