

uvh-TensorRF : 고품질 메시 기반 뉴럴 렌더링

김승진⁰, 손주은, 주광진, 이수현, 이주호, 이승용

POSTECH 컴퓨터공학과, 서강대학교 컴퓨터공학과

{kimsj0302, jeson, gwangjin}@postech.ac.kr, {leesh, jhleecs}@sogang.ac.kr, leesy@postech.ac.kr

요약

최근 딥 러닝 기반의 뉴럴 렌더링 기술은 임의 시점에서의 영상 합성 기술로 주목을 받고 있다. 대표적으로 Neural Radiance Field (NeRF) 기술은 입력 RGB 영상들을 기반으로 임의의 시점에서의 고품질 영상을 렌더링한다. 메시 기반 뉴럴 렌더링 방식은 장면의 수정과 빠른 렌더링 속도를 가능하게 하였지만 렌더링 영상의 품질이 낮다는 문제를 가지고 있다. 본 논문은 새로운 메시 기반 뉴럴 렌더링 방식인 *uvh*-TensorRF 를 제안한다. 해당 기법은 복원된 3 차원 메시지를 기반으로 볼륨 렌더링에 필요한 공간을 제한하고 해당 공간에 딥 러닝 모델의 표현력을 집중하여 렌더링 품질을 높인다. 이를 위해 제한하는 공간을 메시 매개변수화를 통한 *uv*와 법선 방향 거리 *h*로 정의된 *uvh* 좌표계로 표현함으로써 효율적으로 해당 공간을 다루었다. 결과적으로 제안된 방법은 메시 기반 렌더링 방법들 중에서 가장 높은 이미지 렌더링 품질을 달성하였으며 최신 NeRF 연구들과 비슷한 성능을 보였다. 또한 메시지를 사용하기 때문에 장면 변형, 텍스처 교체, 텍스처 필터링과 같은 그래픽스 연산들을 지원한다.

1. 서론

Neural Radiance Field (NeRF) [1]과 같은 뉴럴 렌더링을 통해 새로운 시점에서의 고품질 영상을 렌더링할 수 있다. NeRF는 하나의 multi-layered perceptron (MLP)이 주어진 장면에 대한 색상 및 기하 정보를 학습하도록 하는 기술이다. 뉴럴 렌더링 기술이 발전함에 따라 다양한 기능을 지원하기 위해서 메시, 점구름 등을 사용하여 장면을 표현하는 방식[2, 3]이 제안되었다. 메시 기반 뉴럴 렌더링 방법들은 딥 러닝 모델을 통해 색상과 밀도 정보를 가진 피처를 학습하고, 학습된 피처를 텍스처 또는 메시 정점 상에 저장한다. 이는 메시와 관련된 다양한 응용 기술을 적용 가능하도록 한다. 하지만 메시 기반 방식은 렌더링 품질이 최신 NeRF 연구들에 비하여 낮다는 문제점을 가지고 있다.

본 논문에서는 새로운 고품질 메시 기반 뉴럴 렌더링 방식인 *uvh*-TensorRF 를 제안한다. 해당 방식은 3 차원 복원 기술을 통해 복원된 메시지를 통해 샘플 추출 공간을 제한하고 해당 공간에 딥 러닝 모델의 표현력을 집중한다. 이를 위해 제한된 공간을 메시 매개변수화를 통한 *uv*와 법선 방향 거리 *h*로 정의된 *uvh* 좌표계로 표현하였다. 또한 효율적인 샘플링을 위하여 복원된 초기 메시지를 일정한 오프셋으로 확대/축소하여 샘플링되는 공간을 나타내는 겹층 메시지를 구성하였다. 겹층 메시와 시점 광선들과의 점점들이 추출된 점이며 이들을 구하기 위해서 depth peeling 연산을 이용한 레스터라이저를 사용하였다. 추출된 점들을 볼륨 렌더링 식을 통해서 최종 색상 정보를 예측한다.

실험 결과를 통해 *uvh*-TensorRF 가 메시 기반 방법들보다 고품질의 렌더링 품질을 보이며 최신 NeRF 방식들과 비슷한 성능을 보인다는 것을 확인하였다. 또한 메시지를 사용한다는 특성에 의해 장면 변형, 텍스처 교체 그리고 텍스처 필터링과 같은 다양한 그래픽스 연산들을 지원한다.

본 논문의 기여점은 다음과 같다:

- 메시 주변 지점들을 효율적으로 학습하여 고품질 뉴럴 렌더링을 지원하는 새로운 메시 기반 뉴럴 렌더링 방식인 *uvh*-TensorRF 를 제안한다.
- 제안된 방식은 기존 메시 기반 방식보다 더 좋은 성능을 보이며 최신 NeRF 방식들과 비슷한 성능을 보인다.
- 메시 기반 표현을 바탕으로 다양한 그래픽스 응용기술을 적용할 수 있다.

2. 표면 주변부의 메시 기반 뉴럴 렌더링

주어진 메시와 여러 시점에서의 영상들을 통해 메시 상에서 시점에 따른 영상을 렌더링하기 위한 표면 주변부 뉴럴 텍스처 볼륨을 학습한다.

2.1 파이프라인 개요

주어진 메시 *M*에 대해서 메시 *M*을 감싸는 표면 주변부 볼륨 *V*를 생성한다. *V* 내부의 색상과 밀도는 *uvh* 좌표계 상의 텐서 형태로 피처가 저장된다. 해당 좌표계는 *M*에 대한 2 차원 매개변수화와 오프셋




그림 1. 파이프라인 개요. 초기 메시 M 과 여러 시점에서의 영상들을 입력으로 받는다. (a) 표면 주변부 볼륨 V 를 M 에 높이 오프셋을 적용한 겹층 메시로 표현한다. (b) 추출 점들은 시점 광선과 겹층 메시가 만나는 지점에서 샘플링되고 이후에 추가적인 추출을 진행한다. (c) 볼륨 V 를 (u, v, h) 공간상에서 텐서 표현으로 저장하며 볼륨 렌더링 방식을 통해서 최종 영상을 합성한다.

으로 정의된다. 메시 M 을 통해서 겹층 메시지를 구성하고 겹층 메시 상에서 점들을 추출한다. 추출된 지점들을 볼륨 렌더링 방식으로 합성하여 결과 영상을 만들게 된다 (그림 1). 점 추출에 대한 자세한 사항은 3장에서 다룰 것이다.




그림 2. 표면 주변부 텍스처 볼륨. 주변부의 점(별)은 2차원 표면 상의 위치 (u, v) 와 오프셋 높이 h 로 매개변수화 된다. (a) 각 ϵ -표면은 같은 높이를 가지는 점들의 집합으로 표현된다. (b) ϵ -표면은 높이 범위 $[\epsilon_l, \epsilon_h]$ 내의 3차원 삼각뿔대들로 구성된다.

2.2 표면 주변부 뉴럴 텍스처 볼륨 표현, 공간 표현 및 렌더링

표면 주변부 볼륨 V 에서는 기존 연구와 다르게 uvh 좌표계를 사용한다. 볼륨상에 위치한 하나의 좌표 $x \in V$ 를 2차원 표면상의 지점 (u, v) 와 1차원 오프셋 높이 h 로 변환한다:

$$\mathbf{x} = \mathbf{x}_0(u, v) + h \cdot \mathbf{d}(u, v)$$

위 수식에서 $\mathbf{x}_0$ 는 메시 M 의 매개변수화 함수이며 $\mathbf{d}$ 는 해당 지점에서의 3차원 법선 벡터이다. 오프셋 높이 h 의 범위는 $[\epsilon_l, \epsilon_h]$ 이다. 각 메시의 삼각형은 주어진 오프셋 높이를 통해 3차원 삼각뿔대 형태를 가지게 된다. 이를 통해 표면 주변부 볼륨 V 는 메시 M 을 포함하는 연결된 삼각뿔대들로 구성된다.

볼륨 V 내부의 정보를 효율적으로 학습하기 위해 TensoRF의 표현방식을 기존 (x, y, z) 공간이 아닌 (u, v, h) 공간에서 학습을 진행한다. TensoRF의 방식에서는 다음과 같이 장면을 표현한다:

$$\sigma, c = G_\sigma(\mathbf{x}), \Psi_c(G_c(\mathbf{x}), d)$$

위 수식에서 d 는 시점 방향을 G_σ 와 G_c 는 각각

밀도와 색상에 대한 텐서들을 나타낸다. 피쳐들은 각각 벡터들과 행렬들에 저장되어 있다. TensoRF 표현 방식에 대한 자세한 내용은 [4]에 서술되어 있다.

픽셀 p 지점의 색상 $\hat{c}(p)$ 을 결정하기 위해서는 표면 주변부 볼륨 V 에서 카메라 좌표와 픽셀 p 를 지나가는 시점 광선을 따라가면서 3차원 쿼리 지점들을 추출해야 한다. 그리고 추출한 각 점들의 uvh 좌표를 기반으로 TensoRF 표현을 따라 색상과 밀도들을 얻어낸다. 이후에 볼륨 렌더링 식을 통해서 픽셀 p 의 색상을 결정한다:

$$\hat{c}(p) = \sum_{i=1}^N T_i (1 - \exp(-\sigma(\mathbf{x}_i) \delta_i)) c(\mathbf{x}_i, \mathbf{e})$$

위 식에서 $\mathbf{x}_i$ 는 i 번째 쿼리 점이고, δ_i 는 i 번째와 $i+1$ 번째 쿼리 점 간의 거리이며, T_i 는 카메라에서 i 번째 점의 투과도이다.

3. 겹층 메시지를 통한 쿼리 점 추출

보편적인 볼륨 렌더링을 위한 추출 방식은 시점 광선을 따라가면서 점들을 추출한다. 본 연구에서는 (u, v, h) 공간에서 추출하기 위해 겹층 메시와 래스터라이저를 사용한다.

3.1 겹층 메시 구성

제안된 방식에서 시점 광선의 쿼리 점들은 겹층 메시와 시점 광선의 교점으로부터 구해진다. 겹층 메시는 초기 메시로부터 만들어진 여러 개의 ϵ -표면과 삼각뿔대의 측면들로 구성된다. 주어진 높이 ϵ_i 에 대한 ϵ -표면은 초기 메시 M 에 오프셋을 더하여 정의된다. 각 오프셋 높이 ϵ_i 는 높이 범위 $[\epsilon_l, \epsilon_h]$ 에서 균일하게 추출하였다.

겹층 메시지를 ϵ -표면으로만 구성할 경우 낮은 각도의 표면 지점에 대해서 적게 샘플링이 되는 문제가 발생하여 물체의 경계면에서 낮은 성능을 보이게 된다. 이를 해결하기 위해서 각 삼각뿔대 측면을 추가하여 샘플링을 더 촘촘하게 할 수 있도록 하였




그림 3. DTU 데이터셋에서의 정량적 결과 비교

다.

3.2 Depth Peeling 을 통한 쿼리 점 추출

점들은 레스터라이저의 depth peeling 기능을 통해서 추출된다. Depth peeling 은 순차적으로 카메라에서 가까운 순서대로 점들을 추출할 수 있다. 효율적인 연산을 위해 최대 N_p 번 연산이 진행되도록 설정하였으며 가장 높이가 낮은 ϵ -표면에 도달하면 해당 광선의 탐색이 종료되도록 하였다. 레스터라이저를 활용하기 위해 각 정점의 (u, v, h) 공간 좌표 값을 미리 계산하여 정점 정보로 넣어주었다. 이를 통해 레스터라이저가 무게중심 보간을 통해 추출된 점의 (u, v, h) 좌표를 얻을 수 있다.

3.3 추가적인 선형 추출

추출된 점들을 늘리기 위해서 ϵ -표면을 늘리는 것은 비효율적인 계산량과 메모리 소비를 발생시킨다. 이러한 문제없이 더 많은 추출된 점들을 확보하기 위해, 3.2 장에서의 추출 결과들에 대해서 선형으로 추가 점 추출을 진행하였다. 3 차원 유클리드 공간과 다르게 매개변수 공간에서는 불연속한 추출 지점이 발생할 수 있기 때문에 두 연속된 추출된 점의 거리가 임계 값보다 클 경우 해당 두 점 사이에서는 추가적인 선형 추출을 진행하지 않았다.

4. 실험 및 분석

4.1 초기 메시 획득

주어진 영상들로부터 NeuS2[6]를 활용하여 메시지를 복원하였다. 복원된 메시는 노이즈가 많아 ϵ -표면 구성시에 문제가 발생할 가능성이 있기 때문에 메시 간소화를 통해 30K 와 150K 개의 면을 DTU

데이터셋과 NeRF synthetic 데이터셋이 가지도록 하였다. 이후에 오픈소스 메시 매개변수화[7]를 통해 초기 메시지를 구성하였다.

4.2 손실 함수 및 텐서 크기 설정

이미지 간의 L2 함수 $\mathcal{L}_{img}$ 와 밀도 값의 L1 함수 $\mathcal{L}_{reg}$ 의 가중치 합으로 손실 함수를 구성하고 이를 통해 제안한 모델을 학습한다.

$$\mathcal{L} = \mathcal{L}_{img} + \lambda \mathcal{L}_{reg}$$

DTU 데이터셋에 대해서 $\lambda = 0$ 을 사용하였고, NeRF synthetic 데이터셋에 대해서는 $\lambda = 5 * 10^{-6}$ 을 사용하였다.

실제 공간에서 h 축의 길이가 uv 축에 비하여 작기 때문에 (u, v, h) 텐서의 각 축의 크기를 (512,512,8)로 설정하였다.

표 1. DTU 데이터셋에서의 성능 비교. 각 측정 기준에서 가장 좋은 수치를 굵게, 다음으로 좋은 수치를 밑줄로 표시하였다.

	NeRF	NeuMesh	InstantNGP	Tensorf	Ours
PSNR	25.76	25.51	27.03	26.97	27.53
LPIPS	0.2946	0.2438	0.1801	0.1730	0.1442
SSIM	0.9236	0.9203	0.9393	<u>0.9573</u>	0.9691

표 2. NeRF synthetic 데이터셋에서의 성능 비교. 비교 연구들의 값들은 해당 논문에서 가져온 값을 사용하였다.

	MobileNeRF	NeuMesh	InstantNGP	Tensorf	Ours
PSNR	34.05	30.95	<u>36.25</u>	36.06	34.70
LPIPS	0.976	0.951	-	0.985	0.980
SSIM	0.033	0.043	-	0.022	0.030

4.3 영상 렌더 성능 비교

제안한 모델의 성능을 확인하기 위해 DTU 데이터셋과 NeRF synthetic 데이터셋의 2 개의 공개된 데이터 셋을 사용하였다. 제안된 모델을 NeRF[1], 메시 기반 뉴럴 렌더링 (MobileNeRF[2], NeuMesh[3]) 그리고 격자 기반 뉴럴 렌더링 (TensorRF[4], Instant-NGP[5])과 비교하였다. 정성적 비교 결과는 제안된 방법이 메시 기반 렌더링 기법 중에서 가장 좋은 성능을 달성하였으며 최신 NeRF 연구 결과와 비슷한 결과를 보인다 (표 1, 2). 정량적 비교 결과에서는 제안된 방법이 DTU 데이터셋에 있어서 높은 성능을 보인다 (그림 3).

4.4 응용 기술들

제안한 방법은 메시를 기반으로 하기 때문에 다양한 응용 기술들을 적용할 수 있다. 첫번째로, 장면 변형을 할 수 있다. As-rigid-as-possible (ARAP)과 같은 메시 변형 알고리즘을 통해서 초기 메시를 변형하면 해당 변형에 따라서 표면 주변부 볼륨 V 가 변형되기 때문에 전체 장면을 변형할 수 있다. 두번째로, 텍스처 교체를 할 수 있다. 제안된 표현에서 정보들은 텐서에 저장되어 있기 때문에 특정 (u, v) 위치에 저장된 정보를 다른 정보로 교체한다면 다른 장면에서 얻은 텍스처를 사용할 수 있다. 마지막으로 텍스처 필터링을 할 수 있다. 우리는 각 축에 대한 텐서들을 필터링을 통해서 디테일 수준을 조절할 수 있다.

5. 결론

본 논문은 높은 퀄리티를 가지는 메시기반 뉴럴 렌더링 기법을 제안하였다. 제안된 방식은 기존의 메시기반의 뉴럴 렌더링 방법보다 더 좋은 임의 시점 렌더링 성능을 보였으며, 최신 NeRF 연구들과 비슷한 성능을 보였다. 제안된 방법은 다양한 그래픽스 응용기술에 사용될 수 있다. 현재는 렌더링이 실시간으로 동작하지 않지만 추후 연구를 통해 속도 개선을 통한 실시간 렌더링 기술을 개발할 것이다.

감사의 글

본 논문은 2023 년도 과학기술정보통신부의 재원으로 한국연구재단-중견연구사업(RS-2023-00280400)과 정보통신기획평가원-AI 혁신허브사업(2021-0-02068)의 지원을 받아 수행된 연구입니다.

참고문헌

- [1] Mildenhall, Ben, et al. (2020, August). Nerf: Representing scenes as neural radiance fields for view synthesis. ECCV (pp. 405-421).
- [2] Chen, Zhiqin, et al. (2023). Mobilenerf: Exploiting the

polygon rasterization pipeline for efficient neural field rendering on mobile architectures. CVPR (pp. 16569-16578).

- [3] Yang, Bangbang, et al. (2022, October). Neumesh: Learning disentangled neural mesh-based implicit field for geometry and texture editing. ECCV (pp. 597-614).
- [4] Chen, Anpei, et al. (2022, October). Tensorf: Tensorial radiance fields. ECCV (pp. 333-350).
- [5] Müller, Thomas et al. (2022). Instant neural graphics primitives with a multiresolution hash encoding. ACM ToG, 41(4), 1-15.
- [6] Wang, Yiming, et al. (2023). Neus2: Fast learning of neural implicit surfaces for multi-view reconstruction. ICCV (pp. 3295-3306).
- [7] Zhou, Kun, et al. (2004, July). Iso-charts: stretch-driven mesh parameterization using spectral analysis. Eurographics (pp. 45-54).